1. Bölüm Teorik Temeller

Parametreler :

- Gizli Durumlar (S) : $\{e, v\}$
- Gözlem Dizisi (O) : $[O_1 = High, O_2 = Low]$
- Başlangıç Olasılıkları (π) : $P(e) = 1.0$, $P(v) = 0.0$
- Geçiş olasılıkları (A) :
  - $P(e \to e) = 0.6$
  - $P(e \to v) = 0.4$
  - $P(v \to v) = 0.8$
  - $P(v \to e) = 0.2$
- Emisyon olasılıkları (B) :
  - $P(High | e) = 0.7$, $P(Low | e) = 0.3$
  - $P(High | v) = 0.1$, $P(Low | v) = 0.9$

Hesaplama :

1. Adım : ($t = 1$, $O_1 = High$)

- e durumu için :

$$V_1(e) = P(e) \times P(High | e) = 1.0 \times 0.7 = 0.7$$

- v durumu için

$$V_1(v) = P(v) \times P(High | v) = 0.0 \times 0.1 = 0.0$$

2. Adım: ($t=2$, $O_2 = Low$)

- e durumuna gelme olasılığı ($V_2(e)$):

① $V_1(e) \times P(e \to e) \times P(Low|e) = 0.7 \times 0.6 \times 0.3 = 0.126$

② $V_1(v) \times P(v \to e) \times P(Low|e) = 0.0 \times 0.2 \times 0.3 = 0.0$

Sonuç: $V_2(e) = 0.126$ (Gelen yol: e)

- v durumuna gelme olasılığı ($V_2(v)$):

① $V_1(e) \times P(e \to v) \times P(Low|v) = 0.7 \times 0.4 \times 0.9 = 0.252$

② $V_1(v) \times P(v \to v) \times P(Low|v) = 0.0 \times 0.8 \times 0.9 = 0.0$

Sonuç: $V_2(v) = 0.252$ (Gelen yol: v)

3. Sonuç ve Karar:

En olası fonem dizisi: $e \to v$ (Yani "e-v" dizisi)

Vitrebi Geçiş Matrisi

Zaman (t)	Gözlem (O_t)	Durum: e olasılığı (Gelen yol)	Durum: v olasılığı (Gelen Yol)
$t=1$	High	0.7 (Başlangıç)	0.0 (Başlangıç)
$t=2$	Low	0.126 ($e \to e$)	0.252 ($e \to v$)

Sonuç Fonem Dizisi: {e, v}

3. Bölüm: Analiz ve Yorumlama

1. Ses verisindeki "gürültü" (noise), HMM modelindeki Emisyon Olasılıklarını nasıl etkiler?

Ses verisindeki gürültü, temel olarak gözlem dizisindeki (O) verilerin saflığını bozar. HMM modelinde Emisyon Olasılıkları, belirli bir gizli durumda (fonem) belirli bir gözlemin görülme olasılığını ifade eder. Gürültü olduğunda, örneğin "e" fonemi için normalde yüksek olan "High" frekans olasılığı düşebilir ve "Low" frekans gözlemlenme ihtimali artabilir. Bu durum emisyon matrisindeki olasılık dağılımının "yayılmasına" (daha az belirgin hale gelmesine) ve modelin doğru fonemi ayırt etmekte zorlanarak hata payının artmasına neden olur.

2. Gerçek bir sistemde binlerce kelime olduğunu düşünürsek, Viterbi yerine neden daha karmaşık yapılar (Deep Learning gibi) tercih edilmeye başlanmıştır?
Geleneksel HMM ve Viterbi yaklaşımları, kelime sayısı ve veri karmaşıklığı arttıkça bazı kritik dezavantajlara sahip olur:

* Ölçeklenebilirlik ve Karmaşıklık: Binlerce kelime ve fonem kombinasyonu olduğunda, Viterbi algoritmasının hesaplama yükü ve durum (state) sayısı devasa boyutlara ulaşır.

* Bağlamsal Bağımlılık: HMM'ler "Markov Varsayımı" gereği sadece bir önceki duruma odaklanır. Ancak konuşma dilinde sesler arasındaki uzun süreli ilişkiler çok kritiktir. Derin Öğrenme modelleri (özellikle RNN, LSTM ve Transformer yapıları), bu uzun vadeli bağımlılıkları çok daha başarılı modeller.

* Özellik Çıkarımı: HMM'ler genellikle el ile belirlenmiş özelliklere (örneğin MFCC gibi) ihtiyaç duyarken; Derin Öğrenme, ham ses verisinden en ideal özellikleri kendi kendine öğrenebilir ve farklı aksan/konuşmacı varyasyonlarına karşı çok daha dayanıklı (robust) sonuçlar verir.